

**Mejora en la asignación de recursos con
Particle Swarm Optimization para el
control de enfermedades transmitidas
por mosquitos**

Topiltzin Hernández Mares

23 de marzo de 2022

Índice general

1. Introducción	1
2. Estado del arte	2
2.1. Conceptos básicos	2
2.1.1. Inteligencia artificial	2
2.1.2. Optimización	2
2.1.3. Heurísticas	3
2.1.4. Metaheurísticas	3
2.1.5. Inteligencia de enjambre	3
2.1.6. Algoritmos evolutivos	3
2.1.7. Particle Swarm Optimization	4
2.2. Trabajos relevantes en el área	4
2.2.1. Optimización de ubicación de una red de sensores inalámbricos en un taller inteligente	4
2.3. Comparación	6
2.4. Conclusión	6
3. Problema y justificación	7
4. Solución	8
5. Metodología de evaluación	9
6. Resultados y contribuciones	10
7. Conclusiones	11

Índice de figuras

2.1. Inspiración de algoritmos de inteligencia de enjambre.	3
2.2. Resultados de error de detección de 3D-FOA y 3D-AFOA	5
2.3. Resultados de error de detección con diferente cantidad de nodos	6

Resumen

Capítulo 1

Introducción

Capítulo 2

Estado del arte

Antes de hablar del problema y su solución, es necesario entrar en contexto. Por esto, en la primera sección de este capítulo se definirán conceptos básicos, tales como trampas para mosquitos, las cuales tienen un papel central en el problema. Enseguida, se hablará sobre términos de inteligencia artificial y métodos de optimización, los cuales ayudarán a entender mejor la problemática y su solución.

En la segunda parte de este capítulo se hablará de algunos trabajos recientes para poder entender el estado del arte en problemas de optimización. Sin embargo, por la poca investigación relacionada a la optimización de vigilancia de mosquitos, se analizarán trabajos similares enfocados en redes y monitoreo.

2.1. Conceptos básicos

2.1.1. Inteligencia artificial

En el libro *Artificial Intelligence: A Modern Approach* [1], se define la inteligencia artificial (IA) como máquinas con pensamiento parecido al humano y con acciones racionales.

Una definición más elaborada es la de [2]: IA es un término utilizado para etiquetar a computadoras que imitan funciones humanas cognitivas, tales como aprendizaje y resolución de problemas. De igual manera, se llama inteligencia artificial a algoritmos que trabajan con la misma complejidad que expertos humanos.

2.1.2. Optimización

Puede ser definida como el proceso de encontrar la mejor solución posible entre todas las disponibles. Por lo tanto, la tarea de optimización es modelar algún problema en términos de alguna función de evaluación y emplear algún algoritmo de búsqueda para minimizar (o maximizar) esa función objetivo. Sin embargo, no es posible asegurar que el resultado óptimo será encontrado, ya

que hay problemas demasiado grandes que es imposible encontrar la solución óptima [3].

2.1.3. Heurísticas

En el área computacional de optimización, se llaman heurísticas a los métodos usados para buscar soluciones de alta calidad, sin asegurar la óptima.

Una definición más elaborada la da [4], pues dice que una técnica heurística es un método que busca soluciones buenas (y casi óptimas) con un costo computacional bajo. Sin embargo, estos métodos no son capaces de indicar qué tan cerca de la optimización perfecta se encuentra la respuesta actual dada por una heurística.

2.1.4. Metaheurísticas

Se refiere a técnicas que coordinan, manipulan y guían el comportamiento y soluciones de métodos heurísticos de optimización. Tales métodos pueden ser desde procedimientos de alto nivel o pueden describir las alteraciones posibles para una heurística [5].

Existe una gran cantidad de metaheurísticas [4, 3], más adelante se hablará de algunos métodos, tal como algoritmos genéticos y optimización de enjambre de partículas.

2.1.5. Inteligencia de enjambre

La inteligencia de enjambre es un campo computacional que diseña y estudia algoritmos para buscar soluciones a problemas. Estos algoritmos están inspirados en el comportamiento complejo y, algunas veces, coordinado de enjambres de cualquier organismo natural [3].



Figura 2.1: Inspiración de algoritmos de inteligencia de enjambre.

2.1.6. Algoritmos evolutivos

Son un tipo de algoritmos que buscan soluciones a problemas, tomando inspiración de la selección natural y genética [6, 7]. Estos algoritmos pueden representar cromosomas como cadenas de texto, los cuales son las soluciones a

los problemas; los alfabetos representan genes; y más conceptos tomados de la biología.

2.1.7. Particle Swarm Optimization

Particle Swarm Optimization (PSO) fue inventada por Eberhart y Kennedy en 1995 [8], es un algoritmo estocástico inspirado en el comportamiento de una parvada de aves en busca de alimento. Cada partícula en el algoritmo, que representa una solución al problema, vuela en el espacio de búsqueda, actualizando su velocidad y su posición. La ecuación clásica para actualizar la velocidad de una partícula es 2.1 y para actualizar su posición es 2.2.

$$v_{ij} = v_{ij} + c_1 rand()(p_{ij} - x_{ij}) + c_2 rand()(p_{nj} - x_{ij}) \quad (2.1)$$

$$x_{ij} = x_{ij} + v_{ij} \quad (2.2)$$

Actualmente, el algoritmo PSO canónico (CPSO) o PSO con peso inercial (PSO-iw) es considerado como el PSO estándar [9, 10]. En esta forma de PSO, se introduce una nueva variable w , modificando 2.1 a 2.3. Esta nueva variable equilibra la búsqueda local y global de la solución.

$$v_{ij} = wv_{ij} + c_1 rand()(p_{ij} - x_{ij}) + c_2 rand()(p_{nj} - x_{ij}) \quad (2.3)$$

2.2. Trabajos relevantes en el área

2.2.1. Optimización de ubicación de una red de sensores inalámbricos en un taller inteligente

En 2018, Li et al [11] desarrollaron un nuevo algoritmo con el objetivo de optimizar la ubicación de nodos de una red de sensores inalámbricos (WSN) para minimizar el error de detección de objetos 3D en un taller de manufactura inteligente.

Los autores tomaron inspiración del comportamiento de enjambres de moscas, e implementaron en algoritmo de optimización de moscas (FOA). Sin embargo, este algoritmo presenta un comportamiento 2D, y su problema necesita un análisis en tres dimensiones. Por esto, introdujeron una nueva dimensión en la búsqueda de soluciones, resultando en el algoritmo es 3D-FOA. Como una alternativa, decidieron añadir una variable más a su algoritmo, un peso inercial variable, proveniente de PSO-iw, resultando en un nuevo algoritmo: 3D-AFOA.

Al tener dos algoritmos capaces de optimizar los nodos de la red MSN, realizaron diversos experimentos para comparar dichos métodos. Inicialmente, establecieron la posición fija de 3 nodos de la red y un solo nodo objetivo a detectar en un taller simulado. Establecieron una población de 50 y 500 como número máximo de generaciones en ambos algoritmos. En la figura 2.2 se muestran los resultados obtenidos.




Figura 2.2: Resultados de error de detección de 3D-FOA y 3D-AFOA

Como se puede ver en la figura 2.2, el algoritmo 3D-AFOA tiene un mejor desempeño, pues converge en una mejor solución en menos generaciones.

Con el objetivo de verificar la efectividad del algoritmo, se probó con 3, 4 y 5 nodos fijos en la red para detectar nuevamente un recurso en el taller simulado. Los resultados se muestran en 2.3.

Analizando los resultados expuestos en 2.3, se puede apreciar que, conforme incrementa el número de nodos en el algoritmo, el tiempo de convergencia acelera. Sin embargo, el error de detección de los objetivos, aunque mejora con más nodos, no existe gran diferencia. Esto es debido a que solamente la ubicación de un solo nodo fue optimizada en los algoritmos.

Para finalizar, los investigadores concluyeron que 3D-AFOA es altamente aplicable al problema de optimización en la ubicación de nodos en una red WSN y no requiere de un alto presupuesto computacional para lograr buenas soluciones.




Figura 2.3: Resultados de error de detección con diferente cantidad de nodos

2.3. Comparación

2.4. Conclusión

Capítulo 3

Problema y justificación

Capítulo 4

Solución

Capítulo 5

Metodología de evaluación

Capítulo 6

Resultados y contribuciones

Capítulo 7

Conclusiones

Bibliografía

- [1] S. Russell and P. Norving, “Artificial Intelligence: A modern approach”, 3rd ed. Prentice Hall, New Jersey: Pearson Education, 2009.
- [2] J. M. Spector and S. Ma, “Inquiry and critical thinking skills for the next generation: From Artificial Intelligence back to human intelligence,” *Smart Learning Environments*, vol. 6, no. 1, Sep. 2019.
- [3] E. K. Burke and G. Kendall, “Search methodologies: Introductory tutorials in optimization and decision support techniques”. New York, New York: Springer, 2014.
- [4] V. J. Rayward-Smith, “Modern Heuristic Search Methods”. Chichester, New York: Wiley, 1996.
- [5] F. Glover and M. Laguna, “Tabu Search”. Boston, Massachusets: Kluwer Academic Publishers, 1997.
- [6] C. A. Coello Coello, G. B. Lamont, and D. A. Van Veldhuizen, “Evolutionary algorithms for solving multi-objective problems,” *Genetic and Evolutionary Computation Series*, 2007.
- [7] A. S. Fraser, “Simulation of genetic systems by Automatic Digital Computers II. effects of linkage on rates of advance under selection,” *Australian Journal of Biological Sciences*, vol. 10, no. 4, p. 492, 1957.
- [8] J. Kennedy and R. Eberhart, “Particle swarm optimization,” *Proceedings of ICNN'95 - International Conference on Neural Networks*, 1995.
- [9] Y. Shi and R. Eberhart, “A modified particle swarm optimizer,” 1998 IEEE International Conference on Evolutionary Computation Proceedings. IEEE World Congress on Computational Intelligence (Cat. No.98TH8360), 1998.
- [10] S. Cheg, H. Lu, X. Lei, and Y. Shi, “A quarter century of particle swarm optimization,” *Complex and Intelligent Systems*, vol. 4, no. 3, pp. 227–239, 2018.
- [11] S. Li, C. Zhang, and J. Qu, “Location optimization of wireless sensor network in Intelligent Workshop based on the three-dimensional adaptive fruit

fly optimization algorithm,” International Journal of Online Engineering (iJOE), vol. 14, no. 11, p. 202, Nov. 2018.